

OCRTurk Üzerinde Türkçe OCR ve Diakritik Post-Correction

Turkish OCR and Diacritic Post-Correction on OCRTurk

Arda Karakaş
Ankara Üniversitesi, YZM304 Derin Öğrenme
Ankara, Türkiye

Özetçe - Bu çalışmada OCRTurk veri kümesi üzerinde Türkçe ham metin OCR performansı ve diakritik karakter hataları incelenmiştir. Tesseract ve EasyOCR, erişilebilir açık kaynak baseline olarak çalıştırılmış; çıktılar CER, WER, NED ve Türkçe karakter confusion ölçütleriyle değerlendirilmiştir. Ayrıca satır kırığı, karakter normalizasyonu ve sözlük destekli basit bir post-correction katmanı denenmiştir. Deneyler, Türkçe OCR değerlendirmesinde genel hata oranlarının yanında ç, ğ, ı, ö, ş ve ü gibi karakterlerin ayrı analiz edilmesi gerektiğini göstermektedir.

Anahtar Kelimeler - Türkçe OCR, OCRTurk, diakritik düzeltme, post-correction, belge OCR

Abstract - This paper reviews Turkish OCR challenges and presents a reproducible prototype experiment on OCRTurk. Tesseract and EasyOCR are evaluated as accessible baselines for raw text extraction, character and word error rates, and Turkish diacritic confusions. A lightweight rule and lexicon based post-correction layer is then applied. The results indicate that Turkish OCR should be analyzed not only through generic CER/WER scores, but also through language-specific diacritic errors.

Keywords - Turkish OCR, OCRTurk, diacritic restoration, post-correction, document OCR

I. GİRİŞ

Optical Character Recognition (OCR), doküman görüntülerinden makine tarafından işlenebilir metin çıkarma problemidir. Türkçe için bu problem yalnızca Latin harflerini tanımakla sınırlı değildir; ç, ğ, ı, İ, ö, ş ve ü karakterleri, eklemeli dil yapısı ve PDF tabanlı doküman düzenleri hata davranışını doğrudan etkiler.

Bu çalışmanın amacı yeni bir büyük OCR modeli eğitmek değil, OCRTurk üzerinde erişilebilir OCR motorlarının Türkçe karakter davranışını inceleyen kısa bir derleme ve deneysel ön çalışma sunmaktır. Böylece literatürdeki boşluk, tekrar üretilebilir bir deney hattı ve Türkçe karakter odaklı hata analizi aynı çalışma içinde raporlanmıştır.

Türkçe metinlerde diakritik karakterler yalnızca yazım estetiği değildir; kelimenin anlamını, ek yapısını ve arama/eşleme işlemlerini etkiler. Örneğin 'şeker' ve 'seker', 'oldu' ve 'öldü' gibi biçimler OCR sonrası bilgi çıkarımı, sınıflandırma veya arşiv araması için farklı sonuçlar doğurabilir. Bu nedenle diakritik hataların ayrı bir hata ailesi olarak raporlanması gerekir.

Bu raporda temel araştırma sorusu şudur: Tesseract ve EasyOCR gibi erişilebilir motorlar OCRTurk üzerinde Türkçe ham metin ve diakritik karakterlerde nasıl hata yapmaktadır, basit bir post-correction katmanı bu hataları hangi ölçüde azaltmaktadır? Bu soru, tam belge ayrıştırma yerine ham metin OCR ve dil-özel hata analiziyle sınırlandırılmıştır.

II. İLGİLİ ÇALIŞMALAR

Türkçe OCR literatürü karakter tanıma, fiş ve belge görüntüleri, sahne metni ve el yazısı gibi parçalara ayrılmış durumdadır. Son sistematik değerlendirmeler, veri seti kıtlığı ve açık benchmark eksikliğinin Türkçe OCR için temel sınırlardan biri olduğunu vurgulamaktadır [3]. OCRTurk bu boşluğu azaltarak akademik doküman, tez, sunum ve akademik olmayan belge türlerinden

oluşan 180 sayfalık bir benchmark sağlar [1], [2].

Tesseract ve EasyOCR yaygın, erişilebilir ve tekrar üretilebilir OCR araçlarıdır [5], [6]. PaddleOCR ve modern vision-language yaklaşımları daha güçlü referanslar sunsa da bu çalışmada ana odak, herkesin çalıştırabileceği baseline motorlarda Türkçe diakritik hatalarının nasıl görüldüğüdür [4], [7].

OCRTurk'ün güçlü yönü, tek satır veya kelime görüntüleri yerine gerçek PDF sayfalarını kullanmasıdır. Bu sayfalarda font farklılıkları, tablo ve şekil bölgeleri, matematiksel ifade parçaları, başlık düzeni ve çok sütunlu yapı aynı anda bulunabilir. Bu durum, klasik OCR motorlarının yalnızca karakter tanıma değil, görüntü ön işleme ve okuma sırası açısından da zorlanmasına neden olur.

Post-correction literatüründe iki ana yaklaşım görülür. İlk yaklaşım kural, sözlük ve n-gram tabanlıdır; hesaplama maliyeti düşük ve uygulanması kolaydır. İkinci yaklaşım BERTurk veya mT5 gibi bağlamsal dil modelleriyle aday düzeltme ya da seq2seq yeniden yazmadır [8], [9]. Bu çalışma, kapsamı sınırlı bir prototip için ilk yaklaşımı tercih eder ve dil modeli tabanlı düzeltmeyi gelecek çalışma olarak bırakır.

III. YÖNTEM

OCRTurk klasörleri otomatik keşfedilmiş, PDF dosyaları PyMuPDF ile 300 DPI çözünürlükte PNG görüntülere çevrilmiş ve Markdown ground truth dosyaları düz metne indirgenmiştir. Her motorun ham OCR çıktısı normalize edilmiş, ardından aynı metrik hattından geçirilmiştir.

Post-correction aşamasında önce satır kırığı ve sık karakter normalizasyonları uygulanmış, sonra leave-one-document-out yaklaşımla oluşturulan Türkçe diakritik sözlük kullanılmıştır. Bu tasarım, küçük benchmark üzerinde doğrudan ground truth sızıntısını azaltmak için her sayfanın kendi referans metnini aday sözlükten dışarıda bırakır.

Değerlendirme hattı üç farklı düzeyde ölçüm üretir. CER karakter seviyesindeki edit uzaklığını, WER kelime seviyesindeki bozulmayı, NED ise normalleştirilmiş edit mesafesini verir. Bunlara ek olarak diakritik doğruluğu, yalnızca Türkçe karakter kümesine ait eşleşmeleri ölçerek genel karakter doğruluğunun sakladığı dil-özel hataları ayırır.

Diakritik confusion tablosu referans karakter ile OCR çıktısındaki karşılığını eşler. Bu tabloda ç/c, ğ/g, ı/i, İ/I, ö/o, ş/s ve ü/u gibi dönüşümler; silme, ekleme ve değiştirme işlemleriyle birlikte sayılır. Böylece bir motorun Türkçe karakterleri tamamen kaybedip kaybetmediği ya da yalnızca noktalama benzeri küçük hatalar üretip üretmediği görülebilir.

IV. DENEY DÜZENİ

Deneyler OCRTurk üzerinde 180 öge için Tesseract 'tur' ve EasyOCR 'tr' motorlarıyla yürütülmüştür. Çalışma ayarı 300 DPI olup EasyOCR GPU desteğiyle çalıştırılmıştır. Ana metrikler CER, WER, NED, karakter doğruluğu, kelime doğruluğu, diakritik doğruluğu ve diakritik confusion sayılarıdır.

Değerlendirme iki aşamalıdır: raw aşaması motorun doğrudan OCR çıktısını; corrected aşaması ise basit post-correction sonrası metni temsil eder. Bu ayırım, düşük maliyetli düzeltme katmanının

hangi motorlarda yararlı olduğunu açıkça gösterir.

Deney hattı veri indirme, PDF render, OCR, metrik hesaplama, grafik üretme ve rapor oluşturma adımlarını ayırık bileşenler halinde yürütür. Bu ayırım, aynı veri üzerinde yalnızca OCR motorunu, yalnızca post-correction katmanını veya yalnızca rapor üretimini yeniden çalıştırmayı mümkün kılar. OCRTurk verisi yeniden dağıtılmadığı için çalışmada yalnızca indirme yöntemi ve türetilen metrikler paylaşılır.

Tesseract için Türkçe dil paketi kullanılmıştır. EasyOCR 'tr' okuyucusu GPU desteğiyle çalıştırılmıştır. PaddleOCR kurulumu opsiyonel bırakılmıştır; çünkü bu çalışmanın temel deney koşulu Tesseract ve EasyOCR baseline'larının tam OCRTurk üzerinde tamamlanmasıdır.

V. BULGULAR

Tablo I. Motor ve aşama bazlı ortalama metrikler

Motor	Aşama	CER	WER	D-Acc	D-Err
easyocr	corrected	0.338	0.530	0.907	23.0
easyocr	raw	0.338	0.535	0.896	25.1
tesseract	corrected	0.266	0.434	0.942	5.2
tesseract	raw	0.265	0.430	0.947	4.3


Tablo I, Tesseract'ın bu prototip koşuda EasyOCR'dan daha düşük CER ve WER ürettiğini göstermektedir. EasyOCR için post-correction küçük ama pozitif bir CER/WER iyileşmesi sağlamış; Tesseract için ise aynı basit düzeltme katmanı genel metriklerde hafif gerilemeye yol açmıştır. Bu sonuç, correction katmanının motora duyarlı tasarlanması gerektiğini gösterir.

Tesseract'ın daha düşük CER değeri, klasik OCR motorunun bu veri kümesindeki metin bölgelerini daha kararlı okuduğunu düşündürmektedir. Buna karşılık Tesseract çıktısında post-correction sonrası küçük bir kötüleşme oluşması, basit sözlük düzeltmesinin zaten doğru okunmuş karakterleri gereksiz yere değiştirebildiğini göstermektedir.


EasyOCR tarafında raw ve corrected satırları arasındaki fark daha olumludur. Genel CER düşüşü küçük olsa da diakritik hata sayısındaki azalma daha belirgindir. Bu durum, post-correction katmanının özellikle diakritik karakter restorasyonu için yararlı olabileceğini, fakat genel kelime hatalarını tek başına çözmeye yetmediğini gösterir.

Tablo II. Post-correction etkisi: raw - corrected

Motor	ACER	AWER	AD-Err
easyocr	0.0004	0.0049	2.05
tesseract	-0.0007	-0.0043	-0.85



Şekil 1. CER değerlerinin motor ve aşamaya göre karşılaştırılması




Şekil 2. WER değerlerinin motor ve aşamaya göre karşılaştırılması


Diakritik hata analizi, genel CER/WER skorlarının sakladığı Türkçe karakter davranışını görünür kılar. Özellikle noktalı/noktasız i ve ASCII tabanlı karakter düşmeleri, okunabilir görünen OCR çıktılarında bile Türkçe metin kalitesini düşürmektedir.

Tablo III. En sık ham diakritik karışımları

Motor	Karışım	İşlem	Sayı
easyocr	->i	insertion	3281
easyocr	i->	deletion	2457
easyocr	->ı	insertion	1457
easyocr	ı->	deletion	1300
easyocr	->s	insertion	1231
easyocr	->o	insertion	1060




Şekil 3. Post-correction sonrası CER farkı



Şekil 4. Ortalama diakritik hata sayısı

Şekil 4, EasyOCR çıktısında diakritik hata sayısının Tesseract'a göre daha yüksek olduğunu ve correction sonrasında azaldığını göstermektedir. Tesseract için ise correction katmanının diakritik hata sayısını artırması, sözlük tabanlı kararların motor güveni veya bağlam puanı ile desteklenmesi gerektiğini ortaya koyar.



- [4] Y. Yılmaz, E. G. Hanoğlu, A. G. Özkan, and K. Öztoprak, "Benchmarking OCR and Vision-Language Models for Turkish Text Recognition: A Comprehensive Evaluation Using Synthetic Data," Research Square preprint, 2025, doi: 10.21203/rs.3.rs-7797886/v1. <https://doi.org/10.21203/rs.3.rs-7797886/v1>
- [5] Tesseract OCR contributors, "Tesseract OCR documentation," 2026. <https://tesseract-ocr.github.io/>
- [6] Jaided AI, "EasyOCR: Ready-to-use OCR with 80+ supported languages," GitHub repository, 2024. <https://github.com/JaidedAI/EasyOCR>
- [7] PaddlePaddle, "PaddleOCR: multilingual OCR and document parsing toolkit," GitHub repository, 2026. <https://github.com/PaddlePaddle/PaddleOCR>
- [8] MDZ Digital Library team, "dbmdz/bert-base-turkish-cased: BERTTurk model card," Hugging Face, 2026. <https://huggingface.co/dbmdz/bert-base-turkish-cased>
- [9] L. Xue, N. Constant, A. Roberts, M. Kale, R. Al-Rfou, A. Siddhant, A. Barua, and C. Raffel, "mT5: A Massively Multilingual Pre-trained Text-to-Text Transformer," in Proceedings of NAACL-HLT 2021, pp. 483-498, 2021, doi: 10.18653/v1/2021.naacl-main.41. <https://aclanthology.org/2021.naacl-main.41/>
- [10] C. Sayallar, A. Sayar, and N. Babalık, "An OCR Engine for Printed Receipt Images using Deep Learning Techniques," International Journal of Advanced Computer Science and Applications, vol. 14, no. 2, pp. 833-840, 2023, doi: 10.14569/IJACSA.2023.0140295. <https://doi.org/10.14569/IJACSA.2023.0140295>